

Projet d'examen — Data Collection

Web scraping, nettoyage de données et déploiement d'une application Streamlit

1. Présentation du projet

Ce projet d'examen individuel porte sur la collecte de données via web scraping, leur nettoyage, ainsi que le déploiement d'une application permettant de scraper, visualiser et évaluer les données collectées. Il s'appuie sur deux sources de données distinctes, détaillées ci-dessous.

Le travail est strictement individuel. Toute similarité de code ou de contenu entre deux étudiants sera considérée comme du plagiat et sanctionnée en conséquence.

2. Sources de données

2.1 Source 1 — Books to Scrape

<https://books.toscrape.com/catalogue/page-1.html>

Pagination : l'ensemble des pages disponibles du catalogue, à partir de la page 1 jusqu'à la dernière page.

Variables à extraire :

Variable	Description
V1	Titre du livre
V2	Prix
V3	Disponibilité (en stock / rupture de stock)
V4	Nombre de produits (sur la page)
V5	Note du produit
V6	Nombre de reviews
V7	Description
V8	Type de produit (catégorie)
V9	Tax

2.2 Source 2 — Gaaraas (annonces auto Dakar)

<https://www.gaaraas.com/fr/users/dakar-auto?page=2>

Pagination : 100 pages, à partir de la page 1.

Variables à extraire :

Variable	Description
V1	Marque
V2	Modèle
V3	Année
V4	Prix
V5	Kilométrage
V6	Type de boîte de vitesses
V7	Région de vente

3. Tâches à réaliser

Les tâches suivantes sont à réaliser pour chacune des deux sources de données présentées ci-dessus.

3.1 Scraping et nettoyage (coding)

Scraper et nettoyer les données sur l'ensemble des pages indiquées, en utilisant exclusivement Selenium. L'usage de BeautifulSoup n'est pas autorisé pour cette partie.

3.2 Scraping sans nettoyage (no-code)

Scraper les données brutes, sans les nettoyer, sur l'ensemble des pages indiquées, en utilisant l'outil no-code Web Scraper (extension Chrome).

3.3 Application Streamlit

Mettre en place une application déployée avec Streamlit permettant de :

- scraper des données sur plusieurs pages ;
- télécharger les données brutes issues du scraping no-code Web Scraper (non nettoyées) ;
- visualiser un dashboard des données nettoyées, issues du scraping en Selenium ;
- accéder aux deux formulaires d'évaluation de l'application (Kobo et Google Forms).

3.4 Base de données

Créer une base de données SQL liée à l'application pour le stockage des données collectées (une table par source de données, ou un schéma adapté aux deux sources).

3.5 Formulaires d'évaluation

Créer deux versions du formulaire d'évaluation de l'application : l'une sur Kobo, l'autre sur Google Forms. Les questions, sections, types de champs et logiques conditionnelles à reproduire sont détaillées dans le document de spécification fourni séparément. Les deux formulaires doivent être accessibles directement depuis l'application déployée.

4. Contraintes à respecter

- Rester le maximum possible sur ce qui a été fait en cours, en particulier pour le scraping coding.
- Travail strictement individuel : aucune tolérance sur le plagiat entre étudiants.

5. Livrables

- Lien de l'application déployée.
- Lien du repo GitHub.
- Lien de l'enregistrement vidéo de 10 minutes, structuré comme suit : 8 minutes d'explication du code, 2 minutes de démonstration de l'application.

6. Date de soumission

Vendredi 14 août 2026

Le lien du formulaire de soumission vous sera partagé la veille du deadline.